강원대학교
AI 소프트웨어학과

데이터 전처리

- 데이터프레임 -

KNU
강원대학교

데이터 프레임(Dataframe 이란?)

- 데이터 프레임은 프로그래밍 및 데이터 분석에 일반적으로 사용되는 표 형식의 데이터 구조
- 행과 열로 구성된 다양한 형태를 가지고 있는 리스트의 집합
- 데이터 프레임에서 각 열은 변수 또는 특정 속성을 나타냄
- 각 행은 개별 관찰 또는 데이터 포인트를 나타냄
- 데이터 프레임은 다목적이며 숫자, 범주 및 텍스트 데이터를 포함하여 다양한 유형의 데이터를 처리할 수 있음

데이터 프레임이란?

- 데이터 조작 용이성: 데이터 프레임을 사용하면 행과 열의 추가, 삭제, 수정을 포함하여 데이터를 쉽게 조작할 수 있음
- 조건에 따른 행 필터링, 누락된 데이터 처리, 데이터 세트 병합과 같은 작업은 데이터 프레임을 사용하면 더 간단함
- CSV, Excel, SQL 데이터베이스 및 JSON과 같은 다양한 형식 및 소스에서 데이터 가져오기 및 내보내기에 대한 광범위한 지원을 제공함

데이터 프레임이란?

```
pip install pandas
import pandas as pd
```

```
data = {
        'Name': ['Alice', 'Bob', 'Charlie'],
        'Age': [25, 30, 35],
        'City': ['New York', 'Paris', 'London']
        }

df = pd.DataFrame(data)

print(df)
```

길이가 같아야 생성가능

데이터 프레임이란?

```
pip install pandas
import pandas as pd
```

```
data = np.array([
    [1, 'Alice', 30],
    [2, 'Bob', 25],
    [3, 'Charlie', 35]
])

df = pd.DataFrame(data)

df = pd.DataFrame(data, columns=['ID', 'Name', 'Age'])
```

길이가 같아야 생성가능

TEXT

- 텍스트 파일은 데이터를 저장하고 표현하기 위해 간단하고 널리 사용되는 형식
- 텍스트 파일의 데이터는 일반적으로 각 데이터 포인트가 구분 기호(예: 쉼표 또는 탭)로 구분된 일반 텍스트로 저장됨
- 텍스트 파일의 주요 이점은 단순성과 다양한 프로그래밍 언어 및 소프트웨어 응용 프로그램과의 호환성이 좋음
- 복잡한 데이터 구조에 대한 지원 부족
- 데이터 조작 및 분석 기능이 제한됨
- 고급 데이터 작업을 위해 수동 처리가 필요함

a - Windows 메모장

파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)

키	나이	수학	영어	성적
178	17	81	92	A
188	17	71	75	B
160	17	52	36	C
170	17	55	62	C
175	17	65	47	C
181	17	71	92	B
167	17	67	78	B
158	17	84	68	B
180	17	97	91	A
172	17	100	81	A

Excel

- 특히 .xlsx 형식의 Excel 파일은 Microsoft Excel에서 만들고 사용하는 스프레드시트 파일
- Excel 파일은 데이터 구성, 조작, 시각화 및 분석을 위한 포괄적인 기능 세트를 제공함
- 복잡한 수식, 조건부 서식, 그래픽 표현 및 다양한 데이터 유형을 지원함
- Excel 파일은 사용자 친화적인 인터페이스와 광범위한 기능을 제공하여 기본 및 고급 데이터 관리 작업에 모두 적합함
- 그러나 Excel 파일은 크기가 상대적으로 큼
- 타사 소프트웨어와의 호환성 문제

	A	B	C	D	E
1	키	나이	수학	영어	성적
2	178	17	81	92	A
3	188	17	71	75	B
4	160	17	52	36	C
5	170	17	55	62	C
6	175	17	65	47	C
7	181	17	71	92	B
8	167	17	67	78	B
9	158	17	84	68	B
10	180	17	97	91	A
11	172	17	100	81	A

CSV(Comma-Separated Values)

- 파일은 테이블 형식 데이터 저장 및 교환에 일반적으로 사용되는 특정 유형의 텍스트 파일 형식
- CSV 파일에서 각 행은 데이터 레코드를 나타내며 행 내의 각 필드는 쉼표 또는 기타 지정된 구분 기호로 구분됨
- CSV 파일은 스프레드시트 소프트웨어 및 데이터베이스 응용 프로그램에서 광범위하게 지원되므로 데이터 공유 및 상호 운용성을 위해 많이 사용 가능함
- 데이터를 행과 열로 구성하기 위한 기본 구조를 제공하지만 복잡한 수식이나 서식 옵션은 지원하지 않음
- 복잡한 데이터 구조 또는 수식에 대한 제한된 지원
- 고급 서식 옵션이 부족함

	A	B	C	D	E
1	키	나이	수학	영어	성적
2	178	17	81	92	A
3	188	17	71	75	B
4	160	17	52	36	C
5	170	17	55	62	C
6	175	17	65	47	C
7	181	17	71	92	B
8	167	17	67	78	B
9	158	17	84	68	B
10	180	17	97	91	A
11	172	17	100	81	A

Excel to CSV(Comma-Separated Values)

- 다른이름으로 저장 or 복사본 저장

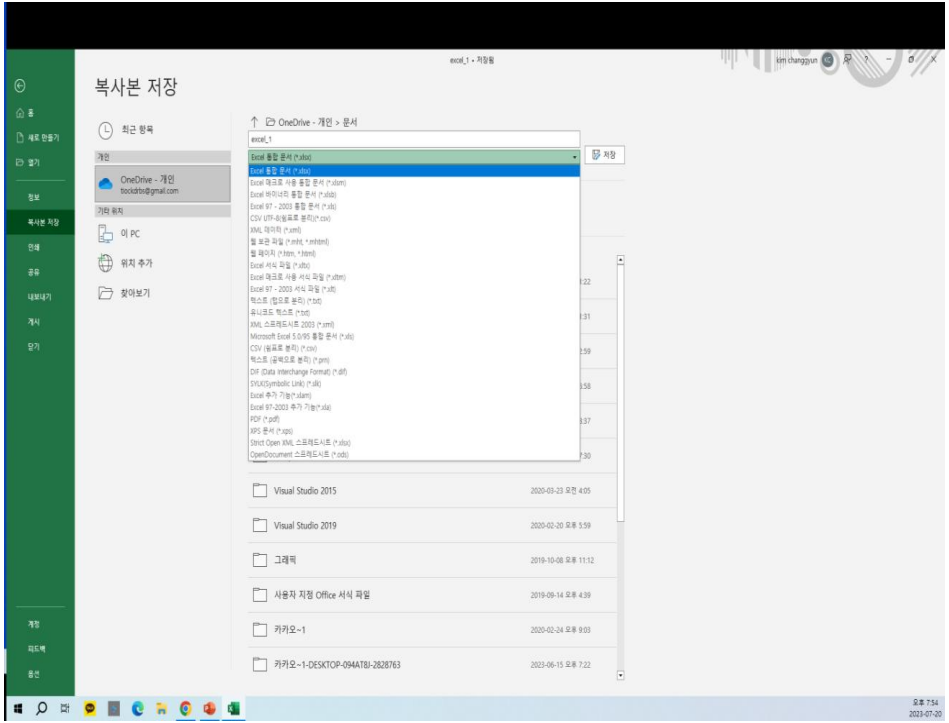

Excel to CSV(Comma-Separated Values)

- 저장 탭에서 csv (쉼표로 분리) 선택

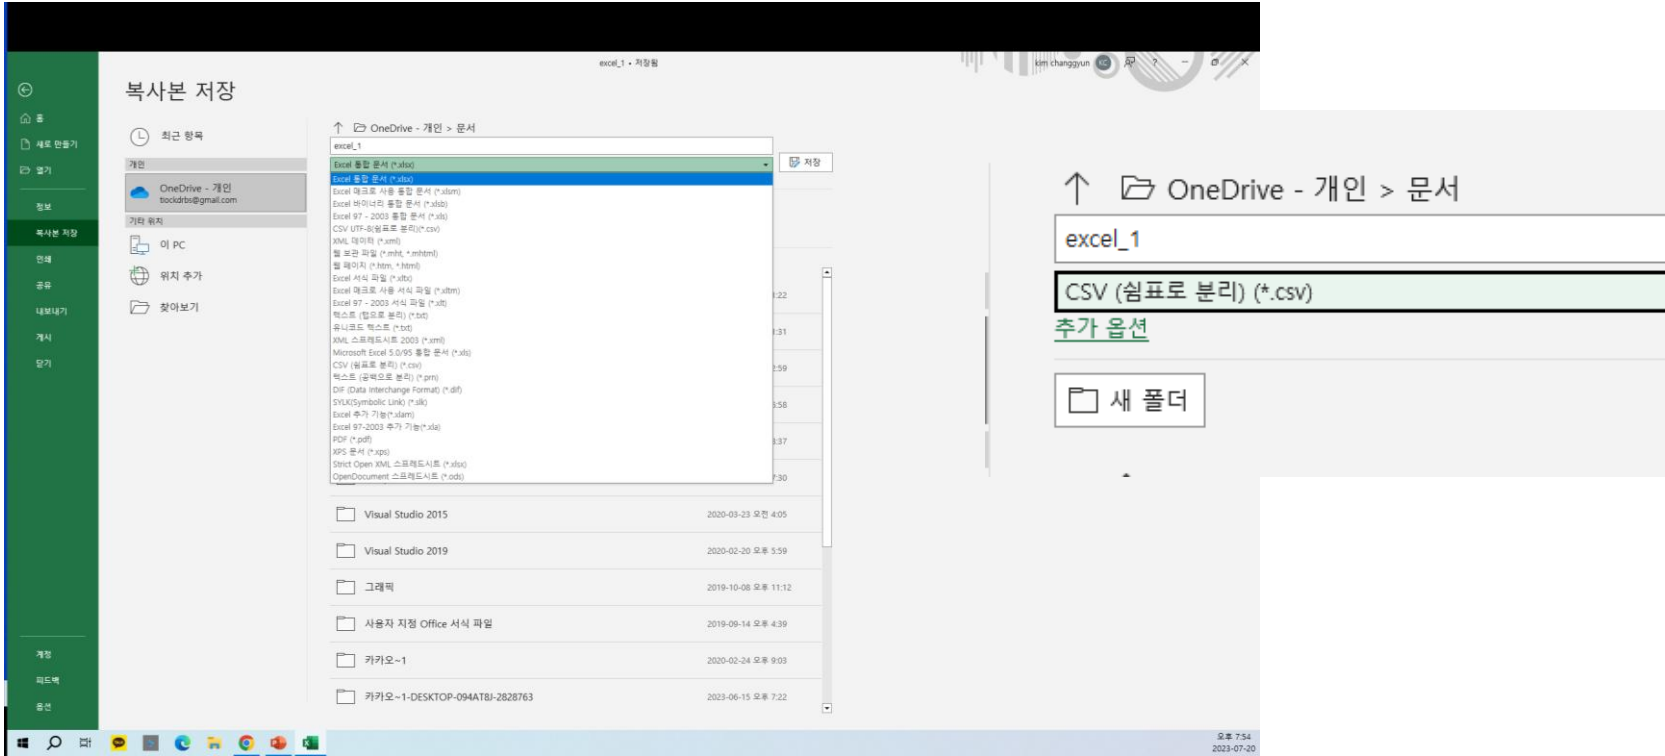

TEXT to CSV(Comma-Separated Values)

- **Excel → 열기 → Text파일 선택**

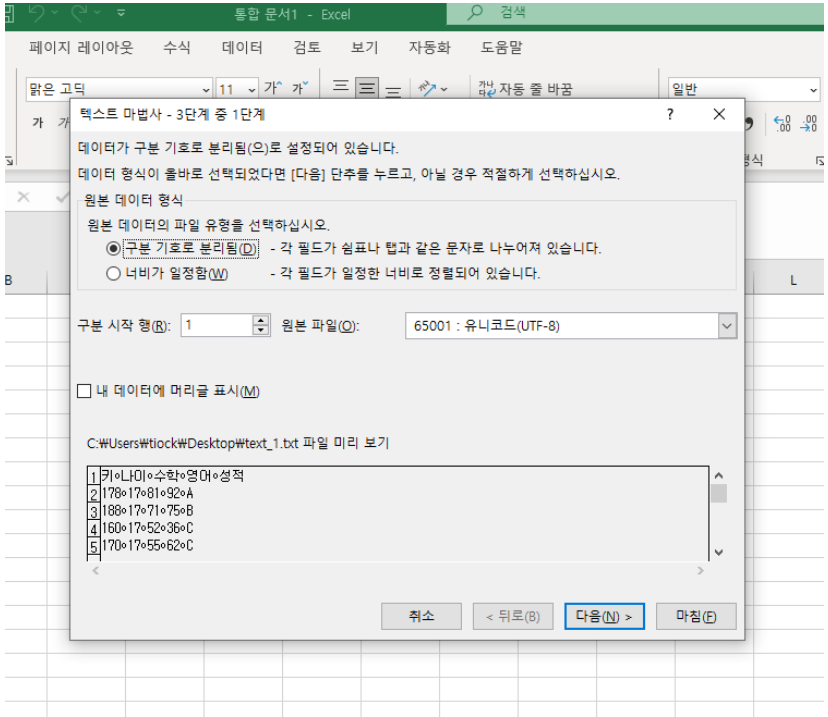

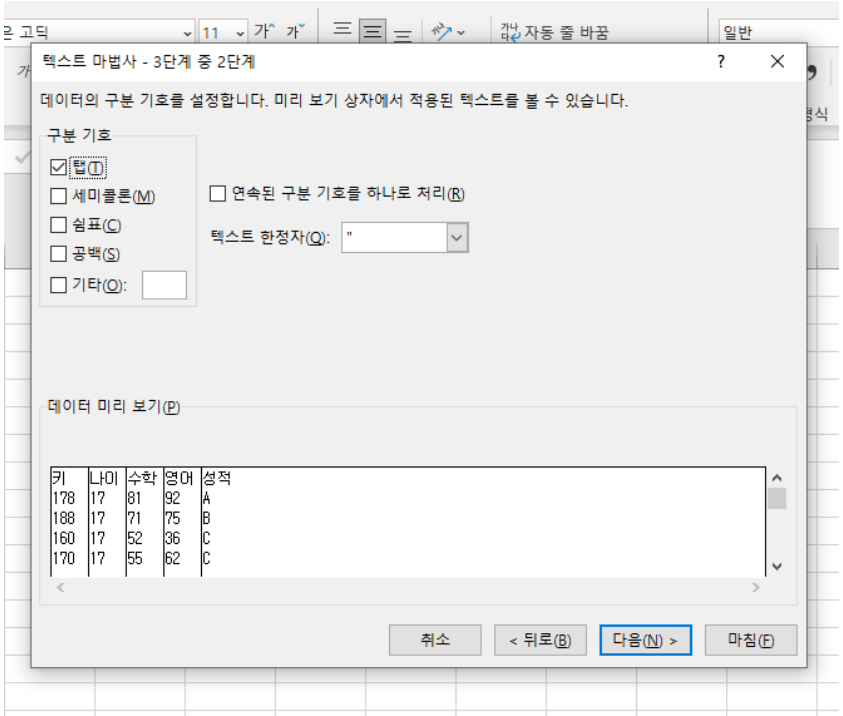

TEXT to CSV(Comma-Separated Values)

- **Excel → 열기 → Text파일 선택**

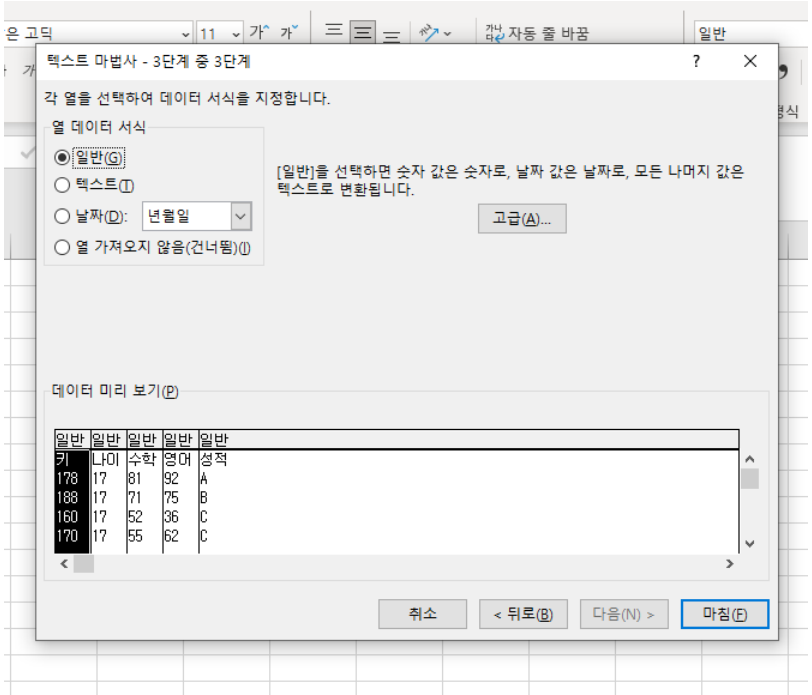

데이터 프레임 불러오기

```
df_h=pd.read_csv('data.csv', header=0)

df_nh= pd.read_csv('data.csv', header=None)

df_utf8 = pd.read_csv('data.csv', encoding='utf-8')

df_cp949 = pd.read_csv('data.csv', encoding='cp949')

df= pd.read_csv('data.csv', header=0, encoding='cp949')
```

- header = 데이터 프레임의 첫 행에 변수명이 있는지 없는지에 따라 0과 None으로 구분됨
- encoding = 영어 이외의 단어들이 들어 갔을 때, 오류가 발생할 수 있으므로 영어 이외의 단어를 인식할 수 있도록 인코딩 하는 방식(주로 한국어는 cp949, euc-kr, utf-8)세 가지로 저장됨

데이터 프레임 불러오기

df=pd.read_csv("data/국영수.csv",encoding='cp949')

df.shape → 데이터 프레임의 차원확인
df.columns → 데이터 프레임의 변수확인
df.dtypes → 데이터 프레임의 변수 타입확인
df.describe() → 수치형 변수들에 대한 요약
df.head() → 위에서 다섯개의 값 도출
df.tail() → 아래에서 다섯개의 값 도출

df.isnull().sum() → 결측값이 몇개인지
df['column'].value_counts() → 카테고리 변수의 어떻게 분포되어 있는지

df['column'].unique() → 카테고리 변수의 값들 중 독립적인 값 보기
df['column'].nunique() → 카테고리 변수의 값들 중 독립적인 값 갯수

데이터 프레임 변수 생성

```
#데이터 프레임 불러오기
df=pd.read_csv("data/국영수.csv",encoding='cp949')

#해당 변수 추출
df["변수명"]

#새로운 변수 생성
df["새로운 변수명"]=df["변수명"]+df["변수명"]

print(df)
```

데이터 프레임 변수 인덱싱

방법 1

```
#하나의 변수 추출
df["변수명"]

#두개 이상의 변수 추출
columns = ['column_a', 'column_b', 'column_c']
selected_columns = df[columns]
```

방법 2

```
#하나의 변수 추출
df.loc[:, "변수명"]

#두개 이상의 변수 추출
columns = ['column_a', 'column_b', 'column_c']
selected_columns = df.loc[:, columns]
```

데이터 프레임 변수 인덱싱

```
#하나의 변수 삭제
df = df.drop(['삭제 변수명'], axis=1)   #axis = 0 → 행을 삭제, 1 → 열을 삭제
```

```
#두개 이상의 변수 삭제
df = df.drop(['column_name1', 'column_name2'], axis=1)
```

데이터 프레임 변수 Type변경

```
data = {
        'A': [1, 2, 3, 4],
        'B': [4.1, 3.5, 2.1, 5.7],
        'C': ['one', 'two', 'three', 'four']
        }

df = pd.DataFrame(data)

df["변수명"].astype('category')

df['A'] = df['A'].astype(float)
df['B'] = df['B'].astype(int)
df['A'] = df['A'].astype('str')
df['C'] = df['C'].astype('category')
```

df.dtypes → 변수별 type 확인

```
df['A'].dtype
df['B'].dtype
df['A'].dtype
df['C'].dtype
```

데이터 프레임 변수 이름변경

```
df = df.rename(columns={'old_name': 'new_name’})
```

```
df = df.rename(columns={
                 'old_name1': 'new_name1’,
                'old_name2': 'new_name2’,
                'old_name3': 'new_name3’
                })
```

데이터 프레임 전처리 – 결측 데이터

df.dropna()는 데이터프레임의 불완전한 데이터가 있는 행을 삭제함

df.fillna(채워넣을 값) 기본값을 제공하여 데이터 누락으로 인해 데이터에 대한 작업이 실패하지 않도록 하기 위해 자주 사용됨

→df.fillna(df.median()) #중앙값으로 대체
→df.fillna(df.mean()) #평균값으로 대체

데이터 프레임 전처리 – 결측 데이터

```
data = {
        'Numeric1': [1, np.nan, 3, 4],
        'Numeric2': [5, 6, np.nan, 8.2],
        'Category': ['dog', np.nan, 'cat', 'dog']
        }

df = pd.DataFrame(data)


A=df.select_dtypes(include=["number"]).columns  #수치가 포함되어 있는 변수들만
df[A]

B=df.select_dtypes(include=[ ' object ' ,  ' category ' ]).columns  #문자와 카테고리 변수들만
df[B]

df[A].fillna(df[A].median())
df[A]. fillna(df[A]. mean())
```

데이터 프레임 합치기

```
df1 = pd.DataFrame({
            'a':['a0','a1','a2','a3'],
            'b':['b0','b1','b2','b3'],
            'c':['c0','c1','c2','c3']
            })

df2 = pd.DataFrame({
            'a':['a2','a3','a4','a5'],
            'b':['b2','b3','b4','b5'],
            'c':['c2','c3','c4','c5'],
            'd':['d2','d3','d4','d5']
            })
```

pd.concat([df1, df2], axis=0) → 행기준으로 합쳐 짐

pd.concat([df1, df2], axis=1) → 열기준으로 합쳐짐

데이터 프레임 전처리 – 데이터 추출 및 변환(수치)

```
data = {
        'Numeric1': [1, np.nan, 3, 4],
        'Numeric2': [5, 6, np.nan, 8.2],
        'Category': ['dog', np.nan, 'cat', 'dog']
        }

df = pd.DataFrame(data)


df[(df['Numeric2'] >= 6) & (df['Numeric2'] <= 10)]
df[(df['Numeric2'] >= 6) | (df['Numeric2'] <= 10)]
```

데이터 프레임 전처리 – 데이터 추출 및 변환(수치)

```
data = {
        'Numeric1': [1, np.nan, 3, 4],
        'Numeric2': [5, 6, np.nan, 8.2],
        'Category': ['dog', np.nan, 'cat', 'dog']
        }

df = pd.DataFrame(data)


df[df['Numeric2']>5] = "5보다 크다"
```

어떠한 문제가 발생함

데이터 프레임 전처리 – 데이터 추출 및 변환(수치)

```
data = {
            '나이': [22, 35, 14, 55, 42]
}

df = pd.DataFrame(data)

 def categorize (data):
    if 0 < data <= 10:
       return "10대"
    elif 10 < data <= 20:
       return "20대"
    elif 20 < data <= 30:
       return "30대“
    else:
       return “30대 이상”

 df['검사나이'] = df['나이'].apply(categorize)
```

데이터 프레임 전처리 – 데이터 추출 및 변환(문자 값-추출)

```
data = {
        'Numeric1': [1, np.nan, 3, 4],
        'Numeric2': [5, 6, np.nan, 8.2],
        'Category': ['dog', np.nan, 'cat', ‘dogg’]
        }

df = pd.DataFrame(data)


filter_df = df[df['Category'] == 'dog’]

filter_df_contains = df[df['Category'].str.contains('do', na=False)]
```

데이터 프레임 전처리 – 데이터 추출 및 변환(문자 값-분리)

```
df = pd.DataFrame({
    'variable': ['value1-value2-value3', 'value4-value5', 'value6']
})


split_df = df['variable'].str.split('나누고 싶은 기준 문자', expand=True)
#expand→ 나눠서 각각 데이터프레임을 생성하도록 만드는 옵션

split_df.columns = ['var1', 'var2', 'var3']
```

데이터 프레임 전처리 – 데이터 추출 및 변환(문자 값-합치기)

```
df = pd.DataFrame({
    'variable': ['value1-value2-value3', 'value4-value5', 'value6']
})
```

df['variable’] = df['variable'].str[0:5] → 해당 위치에 포함되는 문자를 추출함

df['variable’] = df['variable'].str[0:5] + df['variable'].str[6:12]

데이터 프레임 전처리 – 데이터 추출 및 변환(문자 값-합치기)

```
df[‘var1’] = df[‘var1'].astype(str)
df[‘var2'] = df[‘var2'].astype(str)
df[‘var3'] = df[‘var3'].astype(str)

df['combined'] = df[‘var1'] + '-' + df[‘var2'] + '-' + df[‘var3']
```

데이터 프레임 전처리 – 데이터 추출 및 변환(특정 문자 삭제)

```
text = "apple, “
result = text.rstrip(", ")
print(result)

text = "banana, , “
result = text.rstrip(", ")
print(result)

text = “,orange, pear“
result = text.lstrip(", ")
print(result)
```

데이터 프레임 전처리 – 데이터 추출 및 변환(특정 문자 삭제)

```
df = pd.DataFrame({
    '문항1 ' : ['1', '2', '','2'],
    '문항2': ['','2','3','']
})


df = pd.DataFrame(data)
df[ " 문항"] = df[ " 문항1 " ].fillna( "  " ) +  " ,  "  + df[ " 문항2 " ].fillna( "  " )
df[ " 문항 " ] = df[ " 문항1 " ].str.rstrip( " ,  " ) # 원래 열 삭제
df = df.drop(columns=[ " 문항1 " ,  " 문항2 " ])

print(df)
```

데이터 프레임 전처리 – 데이터 추출 및 변환(문자 대체)

```
df = pd.DataFrame({
    'variable': ['value1-value2-value3', "value3-value1-value5", "vvdfvalue165656"]
})
```

```
#특정 문자가 포함되어 있으면 전체를 해당 문자로 변경(앞에서→뒤로 이동하면서 찾음)

df["new_variable"]=df['variable'].str.replace(r'value1.*', 'value1', regex=True)

print(df["new_variable"])
```

데이터 프레임 전처리 – 데이터 추출 및 변환(문자 대체)

```
df = pd.DataFrame({
    'variable': ['value1-value2-value3', "value1-value4-value5", "vvdfvalue165656"]
})
```

```
#특정 문자가 포함되어 있으면 전체를 해당 문자로 변경(전체에서 찾음)

df["new_variable"]=df['variable'].str.extract(r'(value1)')
print(df["new_variable"])

df["new_variable"]=df['variable'].str.extract(r'(value2)')
print(df["new_variable"])
```

데이터 프레임 전처리 – 데이터 추출 및 변환(문자 대체)

```
df = pd.DataFrame({
   'variable': ['value1-value2-value3', ‘value1-value4-value5’, ‘vvdfvalue1']
})
```

↓

```
conti=df[df['variable'].str.contains('value2', na=False)]
```

↓

```
conti['variable'].str.extract(r'(value2)’)
```

데이터 프레임 전처리 – 날짜 및 시간 데이터 처리

```
data = {'date': ['202103151345', '20210315 1345', '0715', '07-15', '20210315','1']}
df = pd.DataFrame(data)
```

```
df['date']=pd.to_datetime(df['date'], format='%Y%m%d %H%M' , errors='coerce')

df['date']=pd.to_datetime(df['date'], format='%H%M' , errors='coerce').dt.time

df['date']=pd.to_datetime(df['date'], format='%Y%m%d', errors='coerce')
```

errors="raise" 변환이 실패하면 오류가 발생함
errors="coerce" 변환이 실패하면 값이 "NaT"로 변환됨
errors="ignore" 변환이 실패하면 원본 데이터의 값을 반환함

데이터 프레임 전처리 – 날짜 및 시간 데이터 처리

```
data = {'hour': ['1', '2', '12', '22','11']}
df = pd.DataFrame(data)
```

```
pd.to_datetime(df['date'], format='%H%M' , errors='coerce').dt.time
```

```
df['hour'].str.rjust(문자의 길이, fillchar='채우고 싶은 문자') #왼쪽 부터 채움
df['hour']=df['hour'].str.rjust(4, fillchar='0') #왼쪽 부터 채움

df['hour'].str.ljust(문자의 길이, fillchar='채우고 싶은 문자') #오른쪽 부터 채움
df['hour']=df['hour'].str.ljust(4, fillchar='0')
```

데이터 프레임 전처리 – 데이터 저장

```
df.to_csv('new_program.csv', index=False)
```

- 전처리한 데이터프레임
- 저장하고 싶은 경로
- Index를 표시할지 하지 않을지

```
df.to_csv('new_program.csv', index=False, encoding= '~~')
```

肄붾뱺	異쒗깭?쒗	?됯퇏	?됯?遺꾨쫄	?꾨뢰	????
A	10:50:00	53.25	??95	12	25
B	12:05:00	54.75	??97	5	21
C	17:20:00	68.25	以?97	4	7
D	11:01:00	72.25	??95	2	4
E	12:20:00	59.75	以?94	7	3
F	14:25:00	53.25	??96	5	21

A	B	C	D	E	F	G
코드	출생시간	평균	평가분류	년도	월	일
A	10:50:00	53.25	하	95	12	25
B	12:05:00	54.75	하	97	5	21
C	17:20:00	68.25	중	97	4	7
D	11:01:00	72.25	상	95	2	4
E	12:20:00	59.75	중	94	7	3
F	14:25:00	53.25	하	96	5	21