

강원대학교
AI 소프트웨어학과

머신러닝1
- 기초통계 -
추론통계(분산의 분포- ANOVA)

F-test 란?


- F-test는 두 집단의 분산이 동일한지를 비교하는 통계적 검정
- 초기에는 각 집단의 평균의 분산(Between-group Variance) → 집단 간의 차이
 - 각 집단의 평균값이 멀리 떨어져 있음 → A집단은 B집단과 차이가 존재함
 - A의 평균으로 부터 B의 평균 까지의 분산 → Between-group Variance → 집단 간의 차이
 - 따라서 분산분석이라 부름(두 집단의 분산이 동일한지 검정)
 - 등분산 가정 여부를 확인할 때 사용(분산의 동질성 검정)

$$F = \frac{s_1^2}{s_2^2}$$

학원	점수	평균	분산
A	75, 76, 74, 75, 76	75.2	0.7
B	80, 81, 79, 80, 81	80.2	0.7
C	85, 86, 84, 85, 86	85.2	0.7
D	66,95,64,95,65	77	270.5

F-분포란?

- F-분포(Fisher-Snedecor distribution) : F-value는 집단의 분산의 비율
- X축은 두 분산의 비율, Y축은 F값이 발생할 확률 밀도 함수 → F-분포도 양수를 가짐
- 집단의 데이터가 동일한 분포를 따르고, 각 집단의 데이터가 서로 독립일 경우 → 자유도가 커질수록 F-분포는 대칭성이 증가함
- 비교하는 집단들 간의 표본은 서로 독립이어야 하며, 이는 한 그룹의 측정값이 다른 그룹의 측정값에 영향을 주지 않아야 함을 의미



$$F = \frac{\chi_1^2/d1}{\chi_2^2/d2} = \frac{s_1^2}{s_2^2}$$

두 카이제곱 분포(=분산 정보)를 서로 비교

서로 크기가 다를 수 있으니 자유도로 나눠 평균 분산을 만든 후 비율 계산

F-test 란?

- F-test는 두 집단의 분산이 동일한지를 비교하는 통계적 검정
- 각 집단의 평균까지의 분산(Between-group Variance) → 집단 간의 차이
 - 각 집단의 평균값이 서로 떨어져 있음 → A집단은 B집단과 차이가 존재함
 - 기준으로 부터 각각의 평균의 분산 → Between-group Variance → 집단 간의 차이

분산분석(F-test)

- 가설 설정
- H_0 : 두집단의 분산은 같다. → 모집단의 분산 = 표본집단의 분산
- H_1 : 두집단의 분산은 차이가 있다. → 모집단의 분산 $\neq$ 표본집단의 분산

분산분석(F-test)

- 가설 설정
- H_0 : 두집단의 분산은 같다.
- H_1 : 두집단의 분산은 차이가 있다.

예제)

Set A: {10.1, 10.2, 10.3, 10.0, 10.1, 10.2, 10.3, 10.0, 10.1, 10.2}

Set B: {9.8, 10.5, 10.2, 9.7, 10.4, 10.3, 9.6, 10.6, 9.9, 10.7}

분산분석(F-test)

```
set_a <- c(10.1, 10.2, 10.3, 10.0, 10.1, 10.2, 10.3, 10.0, 10.1, 10.2) # 분산 작음  
set_b <- c(9.8, 10.5, 10.2, 9.7, 10.4, 10.3, 9.6, 10.6, 9.9, 10.7)    # 분산 큼
```

```
# F-test: 분산 동질성 검정 (양측)  
result <- var.test(set_a, set_b)  
print(result)
```

```
# F-test: 분산 동질성 검정 (단측) : 귀무가설 기각 시 a집단은 b집단보다 분산이 작다.  
var.test(set_a, set_b, alternative = "less")
```

```
# F-test: 분산 동질성 검정 (단측) : 귀무가설 기각 시 a집단은 b집단보다 분산이 크다.  
var.test(set_a, set_b, alternative = "greater")
```

분산분석(F-test)

```
df=read.csv("C:/Users/tiock/Desktop/Machine_set.csv")
```


```
set_a <- subset(df, machine == "A")$value  
set_b <- subset(df, machine == "B")$value
```

```
# F-test: 분산 동질성 검정 (양측)  
result <- var.test(set_a, set_b)  
print(result)
```

```
# F-test: 분산 동질성 검정 (단측) : 귀무가설 기각 시 a집단은 b집단보다 분산이 작다.  
var.test(set_a, set_b, alternative = "less")
```

```
# F-test: 분산 동질성 검정 (단측) : 귀무가설 기각 시 a집단은 b집단보다 분산이 크다.  
var.test(set_a, set_b, alternative = "greater")
```

분산분석(F-test)



분산분석(F-test)

```
set_a <- c(10.2, 10.3, 10.1, 10.0, 10.3, 10.2, 10.1, 10.2, 10.1, 10.3) #기준이 되는 분산 값  
set_b <- c(10.1, 10.0, 10.2, 10.3, 10.0, 10.1, 10.2, 10.1, 10.2, 10.1)  
set_c <- c(10.2, 10.3, 10.3, 10.3, 10.4, 10.3, 10.2, 10.4, 10.3, 10.4)
```

```
var.test(비교대상, 기준, alternative = "less")
```

- 가설 설정
- H_0 : 모집단의 분산 = 표본집단의 분산
- H_1 : 모집단의 분산 $\neq$ 표본집단의 분산

$$F = \frac{\text{비교대상}}{\text{기준}} = \frac{s_1^2}{s_2^2}$$

예제)

기준 부품의 규격이 A에서 B,C 부품의 생산 규격은 차이가 있는가?

분산분석(F-test)

- 가설 설정
- H_0 : 모집단의 분산 = 표본집단의 분산
- H_1 : 모집단의 분산 $\neq$ 표본집단의 분산

예제)

부품의 규격이 $A = \{10.2, 10.3, 10.1, 10.0, 10.3, 10.2, 10.1, 10.2, 10.1, 10.3\}$ 일 때, 이 부품의 분산보다 크거나 작으면 잘못된 설계

- H_0 : 모집단의 분산 = Set ?의 분산($H_0 : \sigma^2 = \text{Set B or C}$)
- H_1 : 모집단의 분산 $\neq$ Set ?의 분산($H_1 : \sigma^2 < \text{Set B or C}, \sigma^2 > \text{Set B or C}$)


예제)

Set A: {10.2, 10.3, 10.1, 10.0, 10.3, 10.2, 10.1, 10.2, 10.1, 10.3}

Set B: {10.1, 10.0, 10.2, 10.3, 10.0, 10.1, 10.2, 10.1, 10.2, 10.1}

Set C: {10.2, 10.3, 10.3, 10.3, 10.4, 10.3, 10.2, 10.4, 10.3, 10.4}

분산분석(F-test)




가설 검정 및 추론통계

- 두 연속 집단의 평균 차이 비교(T-Test, Z-Test)
- 두 명목 집단의 연관성 비교(chi square-Test)
- 두 연속 집단의 분산 차이 비교(F-Test)



- 그룹을 비교할 때 세개 이상의 그룹을 비교할 수는 없을까?
- F-검정을 사용하는 분산분석(ANOVA)은 세 개 이상의 그룹의 평균 차이를 검정하는 방법
- ANOVA는 F-검정을 통해 그룹 간 평균 차이를 검정하는 방법으로, 집단 간 변동(분산)이 집단 내 변동(분산)보다 충분히 크면 평균에 유의한 차이가 있다고 판단하는 방법


분산분석(F-test)



- F-값은 두 가지의 분산의 비율이므로 두 가지의 평균이 필요함
- 변수는 하나이고, 이 안에 속하는 집단이 4개
- 두 가지의 분산을 구할 수 있음
- Between Variance : 전체평균에서 각 집단의 평균이 얼마나 멀리 떨어져 있나?

수치값	집단
10	A
20	B
25	C
21	D
26	B

분산분석(F-test)




- F-값은 두 가지의 분산의 비율이므로 두 가지의 평균이 필요함
- 변수는 하나이고, 이 안에 속하는 집단이 4개
- 두 가지의 분산을 구할 수 있음
- **Between Variance** : 전체평균에서 각 집단의 평균이 얼마나 멀리 떨어져 있나?
- **Within Variance** : 각 집단의 데이터가 각 집단의 평균에서 얼마나 떨어져 있나?
- **Between Variance가 Within Variance보다 크면** → 적어도 어느 한 그룹의 평균값이 전체 평균과는 다르다고 할 수 있음

분산분석(ANOVA)


- 집단 간 분산 (Between-group variance) → 각 집단의 평균이 전체 평균으로부터 얼마나 떨어져 있는지를 나타냄
→ 전체 값의 평균을 기준으로 집단 간 평균 차이를 측정
- 집단 내 분산 (Within-group variance) → 각 집단 내부의 개별 값들이 자기 집단의 평균으로부터 얼마나 떨어져 있는지를 나타냄
→ 각집단의 평균을 기준으로 집단 내부의 값들의 차이를 측정
- 집단 간 분산이 집단 내 분산보다 크면 → 그룹 간 평균 차이가 우연이 아닌 실제 차이일 가능성이 높음
→ 집단 간의 차이가 집단 내의 차이보다 커야 두 집단이 실제로 다른 집단이라고 할 수 있음
→ 따라서 귀무가설(H_0 : 모든 집단 평균에는 차이가 없다.)을 기각
→ 대립가설(H_1 : 적어도 하나의 집단의 평균은 차이가 있다.)을 채택
- 집단 내 분산이 집단 간 분산보다 크면 → 관측된 그룹 간 평균 차이는 우연일 가능성이 높음(집단 간 차이를 밝히는 데는 유의한 결과를 얻지 못함)

분산분석(ANOVA)

- 분산분석(ANOVA) : 세 개 이상의 그룹 평균을 비교하여 평균의 차이가 존재하는지 판단하는 방법
- 집단 간 분산을 집단 내 분산으로 나눈 것 → 분산을 활용해 평균을 비교
 - $F = 1 \rightarrow$ 집단 간 분산 = 집단 내 분산 $\rightarrow$ 평균 차이 없음
 - $F > 1 \rightarrow$ 집단 간 분산 > 집단 내 분산 $\rightarrow$ 평균 차이 있음 (의심)
 - $F < 1 \rightarrow$ 집단 간 분산 < 집단 내 분산 $\rightarrow$ 집단 평균 간 차이가 없고, 오히려 집단 내 불확실성이 더 큼



분산분석(ANOVA)



분산분석(ANOVA)

- 집단 간 분산(Between-group Variance)을 집단 내 분산(Within-group Variance)으로 나눈 것 → 분산을 활용해 평균을 비교
- MSB : Mean Square Between → 집단 간의 평균 차이를 반영, Sum of Squares Between Groups($SS_{between}$)
- MSW : Mean Square Within → 각 그룹 내부의 변동성, Sum of Squares Within Group(SS_{within})

$$F = \frac{\text{Between Variance}}{\text{Within Variance}} = F = \frac{MS_{\text{Between Group}}}{MS_{\text{within Group}}} = F = \frac{SS_{\text{between}}/(k-1)}{SS_{\text{within}}/(N-k)} \quad k = \text{집단의 수}, N = \text{전체 데이터수}$$

$$SS_{\text{between}} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X}_{\text{total}})^2 = \sum (\text{각 그룹의 데이터 개수} \times (\text{각 그룹 평균} - \text{전체 평균}))^2$$

$$SS_{\text{within}} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2 = \sum (\text{그룹 내의 각 데이터 값} - \text{해당 그룹의 평균})^2 \quad \begin{array}{l} n_i = \text{집단 } i \text{의 데이터수} \\ j : \text{각 그룹안의 개별 관측값 번호} \end{array}$$

분산분석(ANOVA)

- 등분산에 대한 ANOVA검정은 두 모집단의 평균이 동일하다(분산의 비율F-값을 이용)는 귀무가설을 검정함
- H_0 : 여러 집단 간의 평균은 차이가 없다.
- H_1 : 적어도 한 그룹의 평균은 차이가 있다.

예제)

작업자 A,B,C 중에 일의 능률의 평균의 차이가 존재할까?

분산분석(ANOVA)

- 작업자에 따라서 생산량의 차이가 있는지 비교 분석
 - 요인(Factor) = 작업자
 - 측정값에 영향을 미치는 요인(factor)이 1개인 실험 : 일원분산분석(one-way ANOVA)
 - 일원 분산 분석은 종속 변수의 평균 사이에 유의한 차이가 있는지 알아볼 수 있도록 함

작업자 A	작업자 B	작업자 C
90	75	82
85	80	76
77	71	88



Score	작업자
90	A
85	A
77	A
75	B
80	B
71	B
82	C
76	C
88	C

분산분석(ANOVA)

• Between Variance

Score	작업자	Group Mean	Between Variance
90	A	84	12.67
85	A	84	12.67
77	A	84	12.67
75	B	75.33	26.11
80	B	75.33	26.11
71	B	75.33	26.11
82	C	82	2.43
76	C	82	2.43
88	C	82	2.43

$$(84-80.44)^2$$

$$(84-80.44)^2$$

$$(84-80.44)^2$$



$$3 \times (84-80.44)^2$$

$$(75.33-80.44)^2$$

$$(75.33-80.44)^2$$

$$(75.33-80.44)^2$$




$$3 \times (75.33-80.44)^2$$

$$(82-80.44)^2$$

$$(82-80.44)^2$$

$$(82-80.44)^2$$



$$3 \times (82-80.44)^2$$

$$SS_{between} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X}_{total})^2$$

$$SS_{between} = 123.66$$

$$df = (k - 1) = 2$$

분산분석(ANOVA)

• Within Variance

Score	작업자	Group Mean	Within Variance
90	A	84	
85	A	84	
77	A	84	
75	B	75.33	
80	B	75.33	
71	B	75.33	
82	C	82	
76	C	82	
88	C	82	

$$(90-84)^2$$

$$(85-84)^2$$

$$(77-84)^2$$

$$(75-75.33)^2$$


$$(80-75.33)^2$$

$$(71-75.33)^2$$

$$(82-82)^2$$

$$(76-82)^2$$

$$(88-82)^2$$



$$SS_{within} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

$$SS_{within} =$$

$$df = N - k = 9 - 3 = 6$$

분산분석(ANOVA)

- 측정값에 영향을 미치는 요인(factor)이 1개인 실험 : 일원분산분석(one-way ANOVA)
 - 다중비교
 - $H_0 : \mu_1 = \mu_2 = \mu_3 \rightarrow$ 작업자는 일의 능률에 영향을 미치지 않는다.
 - $H_1 : \text{not } H_0 \rightarrow$ 어느 집단의 평균에 차이가 발생하고 있는지를 파악하기 위해
 - $\mu_1 \neq \mu_2 = \mu_3$
 - $\mu_1 = \mu_2 \neq \mu_3$
 - $\mu_1 \neq \mu_3 = \mu_2$

예제)

작업자의 작업 점수에 대한 집단의 평균에 차이가 발생하고 있는지를 파악

A: [12, 15, 14, 10]

B: [20, 18, 22, 21]

C: [25, 23, 27, 26]

$$SS_{between} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X}_{total})^2$$

$$SS_{within} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

$$F = \frac{SS_{between}/(k-1)}{SS_{within}/(N-k)}$$

v1 : between-group(자유도)

v2 : within-group(자유도)

$$\bar{X}_A = 12.75, \bar{X}_B = 20.25, \bar{X}_C = 25.25$$

$$\bar{X}_{total} = 19.42$$

$$SS_{between} = 4(12.75 - 19.42)^2 + n_B(\bar{X}_B - \bar{X}_{total})^2 + n_C(\bar{X}_C - \bar{X}_{total})^2 = 316.6$$

$$SS_{within}(Group A)$$

$$(12 - 12.75)^2 = -0.75^2 = 0.5625$$

$$(15 - 12.75)^2 = 2.25^2 = 5.0625$$

$$(14 - 12.75)^2 = 1.25^2 = 1.5625$$

$$(10 - 12.75)^2 = -2.75^2 = 7.5625$$

$$0.5625 + 5.0625 + 1.5625 + 7.5625 = 14.7$$

$$SS_{within}(Group A + B + C)$$

$$14.7 + 8.75 + 8.75 = 32.2$$

$$F = \frac{316/(3-1)}{32.2/(12-3)} \approx 44.2$$

분산분석(ANOVA)

- 일원 분산분석(one-way ANOVA): 두 개 이상의 수준 또는 범주가 있는 하나의 독립변수가 있고, 이를 종속변수와 비교
- 이원 분산분석(Two-way ANOVA): 두 개의 독립 변수가 존재하며, 이 변수들은 개별적으로, 연관적으로 종속변수에 영향을 미치는지 판단하는 것(ex) 식이요법과 운동 수준이 체중 감량에 어떤 영향을 미치는지 알고 싶을 때

종속변수	독립변수
50	A 학원
60	B 학원
70	A 학원
85	B 학원
67	C 학원
88	A 학원
54	C 학원

일원분산분석

종속변수	식이요법	운동 수준
50	A 요법	5(명목/순위)
60	B 요법	5(명목/순위)
70	A 요법	6(명목/순위)
85	B 요법	8(명목/순위)
67	C 요법	5(명목/순위)
88	A 요법	8(명목/순위)
54	C 요법	4(명목/순위)

이원분산분석

분산분석(ANOVA)

일원 분산분석

- 세 개 이상의 독립적인 그룹의 평균 간에 통계적으로 유의미한 차이가 있는지 여부를 테스트함
- 기본적으로 데이터의 전체 분산을 "그룹 간" 분산과 "그룹 내" 분산으로 분해한 다음 F-통계량을 둘의 비율로 계산함

이원 분산분석

- 각 개별 요인의 효과를 테스트하는 것뿐만 아니라 종속 변수에 대한 두 요인 사이에 상호 작용이 있는지를 확인하는데 사용됨
- 상호 작용 : 한 요인의 효과가 다른 요인의 수준에 따라 달라지는가 궁금한 것

가설 검정 및 추론통계

- 독립변수 : 가설의 원인이 되는 변수, 종속변수에 영향을 미치는 변수
- 종속변수 : 가설의 결과가 되는 변수, 독립변수로 영향을 받는 변수

원인

독립 변수(Independent Variable)

설명 변수(Explanatory Variable)

예측 변수(Predictor Variable)

결과

종속 변수(Dependent Variable)

반응 변수(Response Variable)

결과 변수(Outcome Variable)

표적 변수(Target Variable)

가설 검정 및 추론통계

원인

독립 변수(Independent Variable)

결과

종속 변수(Dependent Variable)


- 독립변수: 종속변수에 영향을 미치는 변수 $\longleftrightarrow$ 통계적 독립 : 두 변수 간에 아무런 관련성이 없음
- 상호작용 있음 $\rightarrow$ 두 변수가 개별적으로 효과가 없더라도 결합될 때 특정 결과에 영향을 줄 수 있음
- 통계적 독립이 성립하지 않으며, 상관 가능성 있음 $\rightarrow$ 두 변수가 같이 있을 때 효과가 달라짐
 - Ex) 수면시간과 카페인 섭취는 개별로는 집중력에 미미한 효과지만, 함께 작용하면 큰 차이를 만들 수 있음
- 상관관계 있음 $\rightarrow$ 통계적으로 독립이 아님, 반드시 상호작용이 있는 것은 아님
- 통계적 독립이 아님, 상호작용은 아닐 수 있음 $\rightarrow$ 두 변수는 같이 움직임
 - Ex) 공부 시간이 늘어나면 성적도 올라감

가설 검정 및 추론통계

		Number of Factor				
		두 수준 변수	세개 이상의 수준을 가지는 하나의 변수	두개 이상의 수준을 가진 변수 + 두개 이상의 수준을 가진 변수	두개 이상의 수준을 가진 변수 + 두개 이상의 수준을 가진 변수 + ...n	
Number of Variable	종속변수 1개 (연속형)	T, Z-test F-Test	One-way ANOVA 일원 분산분석	Two-way ANOVA 이원 분산분석	n-way ANOVA n원 분산분석	
	범주형 변수 (n 개)	Chi-Squared				

가설 검정 및 추론통계

- 분산분석(ANOVA)의 종속변수는 연속형
- ANOVA는 데이터 그룹 간의 차이가 통계학적으로 유의한지 알아낼 수 있도록 도와 줌
- ANOVA의 목적은 여러 집단 간 평균이 같다고 볼 수 있는지를 검정하는 것



분산분석(ANOVA)

- 측정값에 영향을 미치는 요인(factor)이 2개 : 이원분산분석(two-way ANOVA)

Growth	비료	물
30	A	Low
35	A	High
37	A	Low
28	A	High
29	B	Low
32	B	High
33	B	Low
36	C	High
35	C	Low
37	C	High

분산분석(ANOVA)

- 측정값에 영향을 미치는 요인(factor)이 2개인 실험 : 이원분산분석(two-way ANOVA)
 - 다중비교
 - $H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_a = 0$ (독립변수 a)
 - H_1 : 독립변수 a 의 집단의 평균 중 하나 이상의 평균이 다름 $\rightarrow$ 독립변수 a 가 유의한 영향(종속변수)을 미침
 - $H_0 : \beta_1 = \beta_2 = \cdots = \beta_b = 0$ (독립변수 b)
 - H_1 : 독립변수 b 의 집단의 평균 중 하나 이상의 평균이 다름 $\rightarrow$ 독립변수 b 가 유의한 영향(종속변수)을 미침
 - 상호작용 효과
 - H_0 : 독립변수 a 와 독립변수 b 사이에는 상호작용이 없다.(종속변수에 영향을 주지 못함)
 - H_1 : 독립변수 a 와 독립변수 b 사이에는 상호작용이 있다.(종속변수에 영향을 줌)

분산분석(ANOVA)

$$SS_A = n_i \sum_{i=1}^a (\bar{X}_i - \bar{X}_{total})^2$$

$$SS_B = n_j \sum_{j=1}^b (\bar{X}_j - \bar{X}_{total})^2$$

$$SS_{A \times B} = n_{ij} \sum_{i=1}^a \sum_{j=1}^b (\bar{X}_{ij} - \bar{X}_i - \bar{X}_j + \bar{X}_{total})^2$$

$$SS_{Total} = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^{n_{ij}} (\bar{X}_{ijk} - \bar{X}_{total})^2$$

$$SS_{between} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X}_{total})^2$$

$$SS_{within} = SS_{Total} - SS_A - SS_B - SS_{A \times B}$$

요인 A가 종속 변수에 영향을 미치는지 여부

$$F_A = \frac{SS_A/n_A - 1}{SS_{within}/(n_A \times n_B \times (n - 1))}$$

요인 B가 종속 변수에 영향을 미치는지 여부

$$F_B = \frac{SS_B/n_B - 1}{SS_{within}/(n_A \times n_B \times (n - 1))}$$

요인 A, B의 상호작용으로 종속변수에 영향

$$F_{A \times B} = \frac{SS_{A \times B}/((n_A - 1)(n_B - 1))}{SS_{within}/(n_A \times n_B \times (n - 1))}$$

분산분석(ANOVA)

$$SS_A = n_i \sum_{i=1}^a (\bar{X}_i - \bar{X}_{total})^2$$

$$SS_B = n_j \sum_{j=1}^b (\bar{X}_j - \bar{X}_{total})^2$$

$$SS_{A \times B} = n_{ij} \sum_{i=1}^a \sum_{j=1}^b (\bar{X}_{ij} - \bar{X}_i - \bar{X}_j + \bar{X}_{total})^2$$

$$SS_{Total} = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^{n_{ij}} (\bar{X}_{ijk} - \bar{X}_{total})^2$$

$$SS_{between} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X}_{total})^2$$

$$SS_{within} = SS_{Total} - SS_A - SS_B - SS_{AXB}$$

$$F_A = \frac{SS_A/n_A - 1}{SS_{within}/(n_A \times n_B \times (n - 1))}$$

$$F_B = \frac{SS_B}{n_B - 1}, F_{AXB} = \frac{SS_{AXB}}{n_A \times n_B - 2}, MS_{within} = \frac{SS_{within}}{df_{within}}$$

등분산 검정

- 등분산성 검정은 ANOVA에서 평균 차이를 공정하게 비교할 수 있는 조건이 맞는지 확인하기 위해 실시함
- 집단들의 분산이 서로 비슷한지 확인하는 검정 → 분산은 각 집단 안의 값들이 평균 주변에 얼마나 퍼져 있는지
- H_0 : 각각의 집단의 분산은 같다.
- H_1 : 적어도 하나의 집단 분산은 다르다.
- 실제로는 유의하지 않은데 유의하거나 하지 않게 나올 수 있음(p-value가 과소 또는 과대 추정)

```
library(car)      #등분산검정
```

```
#fertilize에 대한 등분산 검정
```

```
leveneTest(growth ~ fertilizer, data = grow)
```

```
#fertilizer, water, 상호작용 전체에 대한 등분산 검정
```

```
leveneTest(growth ~ interaction(fertilizer, water), data = grow)
```

분산분석(ANOVA)

- 등분산성은 만족하지만, 평균 차이는 유의할 수 있음
- A카페: 4,800원, 5,000원, 5,200원
- B카페: 5,800원, 6,000원, 6,200원
- C카페: 6,800원, 7,000원, 7,200원
- 세 카페 모두 가격 차이는 약 400원 정도로 비슷함(메뉴 가격의 퍼짐 정도는 비슷함)
- A카페 평균은 약 5,000원, B카페 평균은 약 6,000원, C카페 평균은 약 7,000원(평균 가격의 차이가 있음)
- 어느 카페의 가격이 너무 들쭉날쭉해서 평균 차이가 이상하게 보이는 것 아닌가? 를 판단하기 위해 필요

분산분석(ANOVA)

- ANOVA의 집단 간 차이 = 평균 차이, Levene 검정의 집단 간 차이 = 분산 차이
- H_0 : Fertilizer의 집단에 따라 growth의 값은 차이가 없다. → 영향을 미치지 않는다.
- H_1 : Fertilizer의 집단에 따라 growth의 값은 차이가 존재한다. → 영향을 미친다.

```
grow <- read.csv("growth.csv", stringsAsFactors = TRUE) #문자형 변수를 요소로 변환
```

```
# 이원분산분석(독립변수들간 상호작용X)
```

```
anova_result <- aov(growth ~ fertilizer + water, data = grow)  
summary(anova_result)
```

```
# 이원분산분석(독립변수들간 상호작용)
```

```
anova_result <- aov(growth ~ fertilizer * water, data = grow)  
summary(anova_result)
```

사후검정

- Tukey 검증 : 각 그룹의 샘플의 수가 같고 분산이 유사할 경우에 주로 사용
- games-howell 검증 : 각 그룹의 샘플의 수가 서로 다르고, 분산이 유사하지 않을 경우에 주로 사용 (불균형 설계)

```
library(rstatix) #games_howell_test  
library(multcomp) #Tukey 사후검정
```

```
#Levene 검정으로 p-value>0.05일 때, Tukey 사후검정(등분산검정을 통해 등분산일 경우)  
tukey_result <- glht(anova_result, linfct = mcp(fertilizer = "Tukey"))  
summary(tukey_result)
```

```
# Levene 검정으로 p-value<0.05일 때, games-howell 사후검정(등분산검정을 통해 등분산이 아닐 경우)  
games_howell_test(grow, growth ~ fertilizer)
```

```
#사후검정(water)  
tukey_result <- glht(anova_result, linfct = mcp(water = "Tukey"))  
summary(tukey_result)  
games_howell_test(grow, growth ~ water)
```

사후검정

- Tukey 검증 : 각 그룹의 샘플의 수가 같고 분산이 유사할 경우에 주로 사용
- games-howell 검증 : 각 그룹의 샘플의 수가 서로 다르고, 분산이 유사하지 않을 경우에 주로 사용 (불균형 설계)

1. 조합집단 생성

```
grow$group <- interaction(grow$fertilizer, grow$water)
```

2. group을 factor로 지정

```
grow$group <- as.factor(grow$group)
```

3. ANOVA 모형 생성

```
anova_group <- aov(growth ~ group, data = grow)
```

4. Tukey 사후검정

```
tukey_result <- glht(anova_group, linfct = mcp(group = "Tukey"))
```

5. 결과 확인

```
summary(tukey_result)
```

사후검정

- Tukey 검증 : 각 그룹의 샘플의 수가 같고 분산이 유사할 경우에 주로 사용

Linear Hypotheses:	평균의 차이			P-value	
	Estimate	Std. Error	t value	Pr(> t)	
B.High - A.High == 0	2.9610	0.7639	3.876	0.00375	**
C.High - A.High == 0	9.9800	0.7639	13.064	< 0.001	***
A.Low - A.High == 0	-0.5220	0.7639	-0.683	0.98308	
B.Low - A.High == 0	0.1390	0.7639	0.182	0.99997	
C.Low - A.High == 0	2.0760	0.7639	2.718	0.08827	.
C.High - B.High == 0	7.0190	0.7639	9.188	< 0.001	***
A.Low - B.High == 0	-3.4830	0.7639	-4.559	< 0.001	***
B.Low - B.High == 0	-2.8220	0.7639	-3.694	0.00647	**
C.Low - B.High == 0	-0.8850	0.7639	-1.158	0.85419	
A.Low - C.High == 0	-10.5020	0.7639	-13.747	< 0.001	***
B.Low - C.High == 0	-9.8410	0.7639	-12.882	< 0.001	***
C.Low - C.High == 0	-7.9040	0.7639	-10.346	< 0.001	***
B.Low - A.Low == 0	0.6610	0.7639	0.865	0.95308	
C.Low - A.Low == 0	2.5980	0.7639	3.401	0.01510	*
C.Low - B.Low == 0	1.9370	0.7639	2.536	0.13196	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					
(Adjusted p values reported -- single-step method)					

사후검정

- games-howell 검증 : 각 그룹의 샘플의 수가 서로 다르고, 분산이 유사하지 않을 경우에 주로 사용 (불균형 설계)

A tibble: 15 × 8

평균의 차이

P-value

.y.	group1	group2	estimate	conf.low	conf.high	p.adj	p.adj.signif	
* <chr>	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<chr>	
1	growth	A.High	B.High	2.96	0.156	5.77	3.6 e- 2	*
2	growth	A.High	C.High	9.98	7.90	12.1	1.43e-10	****
3	growth	A.High	A.Low	-0.522	-2.63	1.58	9.66e- 1	ns
4	growth	A.High	B.Low	0.139	-2.09	2.37	1 e+ 0	ns
5	growth	A.High	C.Low	2.08	-0.295	4.45	1.06e- 1	ns
6	growth	B.High	C.High	7.02	4.25	9.78	7.47e- 6	****
7	growth	B.High	A.Low	-3.48	-6.26	-0.704	1 e- 2	**
8	growth	B.High	B.Low	-2.82	-5.68	0.0356	5.4 e- 2	ns
9	growth	B.High	C.Low	-0.885	-3.83	2.06	9.24e- 1	ns
10	growth	C.High	A.Low	-10.5	-12.5	-8.47	3.8 e-11	****
11	growth	C.High	B.Low	-9.84	-12.0	-7.67	4.48e-10	****
12	growth	C.High	C.Low	-7.90	-10.2	-5.59	5.51e- 8	****
13	growth	A.Low	B.Low	0.661	-1.53	2.85	9.25e- 1	ns
14	growth	A.Low	C.Low	2.60	0.263	4.93	2.4 e- 2	*
15	growth	B.Low	C.Low	1.94	-0.506	4.38	1.7 e- 1	ns

Group2-Gropu1으로 봐야 함 헛갈림 주의

사후검정

- Tukey 검증 : 각 그룹의 샘플의 수가 같고 분산이 유사할 경우에 주로 사용
- games-howell 검증 : 각 그룹의 샘플의 수가 서로 다르고, 분산이 유사하지 않을 경우에 주로 사용 (불균형 설계)

```
read.csv("cafe.csv", stringsAsFactors = TRUE)
```

```
#등분산검정
```

```
#분산분석(독립변수간 상호작용 x)
```

```
#사후검증
```

```
카페 손님들의 만족도에 좋은 영향을 미치는 각변수별 항목들은 무엇인가?
```

가설 검정 및 추론통계

T-test, Z-test

A집단	B집단
연속형	연속형
연속형	연속형
연속형	연속형
연속형	연속형

카이제곱 분석

A요인 \ B요인	B요소_1	B요소_2
A요소_1	범주형	범주형
A요소_2	범주형	범주형

ANOVA(일원분산분석)

집단(종속)	B요인(독립)
연속형	범주형_요소1
연속형	범주형_요소2
연속형	범주형_요소3

F-test

A집단	B집단
연속형	연속형
연속형	연속형

ANOVA(이원분산분석)

집단(종속)	A요인(독립)	B요인(독립)
연속형	범주형_요소1	범주형_요소1
연속형	범주형_요소2	범주형_요소2
연속형	범주형_요소3	범주형_요소3